

Кирилл Козлов

Forward Deployed Engineer (ИИ / LLM, Python)

Москва, Россия (GMT+3), рассматриваю удалённую работу и релокацию

Телефон: +7 (910) 968 1153 | Email: kirillandreevickozlov@yandex.ru | Telegram: [@noobmaster_rus](https://t.me/noobmaster_rus)

GitHub: github.com/noobmaster-ru | LinkedIn: linkedin.com/in/kirill1kozlov

О себе

Forward Deployed Engineer: беру бизнес-задачу заказчика, довожу LLM-систему от прототипа до production и отвечаю за измеримый результат. В департаменте ИИ-агентов X5 Tech запустил три решения для внутренних заказчиков: мультиагентную систему проверки договоров для юридического департамента (свыше 500 проверок на проде, заключение за 8–19 минут вместо около 97, эффект 8 FTE), обработку коммунальных платежей на OCR (эффект 10 FTE) и сервис анализа иностранных инвойсов на OCR и LLM (от первого коммита до пилота на проде менее чем за три месяца). С сентября 2026 в X5 Import разрабатываю систему для 90% иностранных поставок X5 Retail Group. Магистратура ВМК МГУ по машинному обучению.

Ключевые навыки

LLM-системы: agentic workflows, мультиагентные системы и оркестрация агентов, RAG (Retrieval-Augmented Generation), BM25, промпт-инжиниринг, LangChain, OpenAI API, open-weight LLM через Ollama (Llama 3.2, Qwen 2.5, Qwen3-VL), распознавание документов (OCR), извлечение ключевых сущностей из документов

Качество и надёжность: метрики латентности по агентам (Grafana), таймауты и бюджеты для долгих OCR- и LLM-вызовов, подбор модели под задачу, A/B-тестирование (A/B testing)

Поставка и интеграция: end-to-end ownership от постановки задачи до production, быстрое прототипирование, интеграция с системами заказчика (REST API, Apache Kafka), закрытый контур и on-premise, Kubernetes (K8s), Helm, GitLab CI/CD

Инструменты разработки: Claude Code (ежедневно), Git, Docker, Linux

Бэкенд и данные: Python, SQL; FastAPI, SQLAlchemy (async), Alembic, Pydantic, pytest, asyncio, httpx; PostgreSQL, Redis, Apache Kafka

Языки: русский — родной, английский — Upper-Intermediate (B2)

Опыт работы

Forward Deployed Engineer (Junior) | X5 Import, отдел логистических решений | Сентябрь 2026 — н. в.

- Разрабатываю систему, обслуживающую 90% иностранных поставок X5 Retail Group для её торговых сетей.

Forward Deployed Engineer (стажёр) | X5 Tech, департамент ИИ-агентов, Москва | Апрель 2026 — Август 2026

- Довёл от прототипа до production мультиагентную систему проверки договоров для юридического департамента: оркестрация агентов на LangChain (обработка документов, извлечение реквизитов, проверка контрагента и объекта недвижимости, анализ рисков, юридическое заключение), разделы договора анализируются параллельно. Свыше 500 проверок на проде за май–август 2026; заключение за 8–19 минут вместо около 97 минут работы юриста; эффект 8 FTE.
- Развернул open-weight LLM в закрытом корпоративном контуре: Llama 3.2, Qwen 2.5 и Qwen3-VL (для сканов) через Ollama наряду с OpenAI GPT-4o-mini; Kubernetes dev и prod через Helm и GitLab CI/CD.
- Обеспечил надёжность и наблюдаемость пайплайна: метрики латентности по каждому агенту в Grafana, бюджеты и таймауты для минутных OCR- и LLM-вызовов.
- Собрал RAG-источник по российскому законодательству (40 федеральных законов, 366 статей, включая ГК РФ, BM25-индекс) с подстановкой релевантных статей в промпты агентов.
- Реализовал извлечение ключевых сущностей из договоров, выписок ЕГРН и доверенностей через OCR и LLM с проверкой согласованности атрибутов между документами.
- Выпустил сервис анализа иностранных инвойсов на OCR и LLM для бизнес-единицы X5 Import: от первого коммита в июне 2026 до деплоя на dev и prod и пилота с интеграцией во внутреннюю платформу в августе 2026.
- Встроил обработку коммунальных платежей в существующий ландшафт X5 Group: бэкенд на FastAPI принимает результаты OCR из Apache Kafka, хранит и отдаёт во фронтенд; эффект 10 FTE.

Проекты (запущены для реальных пользователей)

AxiomAI (Telegram-бот на LLM) | github.com/noobmaster-ru/axiomai | Октябрь 2025 — Апрель 2026

- Разработал и развернул бота на aiogram с OpenAI API, PostgreSQL, Redis и Docker для бизнес-коммуникаций с клиентами; снизил нагрузку на менеджеров на 80%.

Образование

МГУ имени М.В. Ломоносова, магистратура | Факультет ВМК, кафедра математических методов прогнозирования (ММП), машинное обучение | Сентябрь 2026 — настоящее время

МГУ имени М.В. Ломоносова, бакалавриат | Факультет вычислительной математики и кибернетики (ВМК) | Август 2022 — Август 2026

- Летняя школа по A/B-тестированию (A/B testing), X5 Tech — лето 2026 ([сертификат № 9074503](#)).
- Deep Learning School (DLS), направления Computer Vision и NLP — Школа глубокого обучения МФТИ.