Кирилл Козлов

Junior ML-разработчик (Python, LLM, RAG)

Москва, Россия | Телефон: +7 (910) 968 1153 | Email: kirillandreevickozlov@yandex.ru
GitHub: github.com/noobmaster-ru | Telegram: @noobmaster_rus

О себе

Разработчик, бакалавр ВМК МГУ и магистрант по машинному обучению. В X5 Tech разрабатывал и запускал Python-сервисы на FastAPI, PostgreSQL и Kubernetes. В проекте «Корзина» разрабатываю ИИ-поиск товаров и систему обработки каталога.

Ключевые навыки

Языки программирования: Python, SQL
Искусственный интеллект и ML: большие языковые модели (LLM), LLM-агенты, RAG (Retrieval-Augmented Generation), BM25, OpenAI API, LangChain, промпт-инжиниринг, распознавание документов (OCR), A/B-тестирование (A/B testing), Claude Code
Фреймворки: FastAPI, SQLAlchemy (async), Alembic, Pydantic, pytest
Библиотеки: asyncio, httpx, aiohttp, pandas, NumPy, scikit-learn, structlog
Базы данных и очереди: PostgreSQL, Redis, Apache Kafka
Инфраструктура и DevOps: Docker, Kubernetes (K8s), Helm, GitLab CI/CD, Git, Linux
Языки: русский — родной, английский — Upper-Intermediate (B2)

Опыт работы

Software Engineer (Junior) | X5 Tech, отдел логистических решений | Октябрь 2026 — настоящее время

- Разрабатываю систему, обслуживающую 90% иностранных поставок X5 Retail Group для её торговых сетей.

ML-разработчик (стажёр) | X5 Tech, департамент ИИ-агентов, Москва | Апрель 2026 — Октябрь 2026

- Разработал LLM-агента на LangChain для проверки договоров: свыше 500 проверок на проде за май–август 2026, заключение за 8–19 минут вместо около 97 минут ручной работы юриста; экономический эффект для X5 Group — 8 FTE.
- Реализовал поиск по корпусу законодательства для RAG: 40 федеральных законов, 366 статей (в том числе ГК РФ), BM25-индекс, подстановка релевантных статей в промпт агента.
- Разработал бэкенд на FastAPI для сервиса обработки коммунальных платежей: приём результатов OCR из Apache Kafka, хранение и выдача во фронтенд; экономический эффект — 10 FTE.
- Разработал и развернул на dev и prod сервис анализа иностранных инвойсов на OCR и LLM для X5 Tech; с августа 2026 в пилотной эксплуатации.
- Развернул сервисы в кластере Kubernetes (dev и prod) через Helm и GitLab CI/CD; латентность агентов отслеживается в Grafana.

Проекты

Корзина — маркетплейс и ИИ-поиск товаров | TypeScript, Node.js, PostgreSQL, React | Сентябрь 2026 — настоящее время

- Разрабатываю Telegram Mini App и бота с каталогом более 100 тыс. товаров; автоматизировал сбор, нормализацию и дедупликацию данных поставщиков.
- Реализовал полнотекстовый и триграммный поиск в PostgreSQL; разрабатываю прототип гибридного поиска: мультимодальные эмбеддинги Gemini, pgvector, объединение текстовых и визуальных кандидатов через RRF, реранжирование Qwen.
- В прототипе реализовал извлечение характеристик через LLM/VLM и проверку совместимости товаров; версионируемый кэш эмбеддингов, защиту от параллельных повторов и обновление изменённых карточек.
- Подготовил офлайн-оценку релевантности: фиксированные датасеты, qrels, Recall@20 и Precision@5; сравнение текстового и мультимодального поиска с учётом задержек и стоимости моделей.
- Реализовал Fastify API и фоновые задачи; PostgreSQL, Valkey, S3, Docker и GitLab CI/CD для развёртывания и эксплуатации сервиса.

Другие проекты: AxiomAI — Telegram-бот на LLM, снижение нагрузки на менеджеров на 80%; WB Parser — поиск Wildberries и Mini App, 220 пользователей; Placa — аналитика для 300 продавцов.

Образование

МГУ имени М.В. Ломоносова, магистратура | Факультет ВМК, кафедра математических методов прогнозирования (ММП), машинное обучение, Москва | Сентябрь 2026 — настоящее время

МГУ имени М.В. Ломоносова, бакалавриат | Факультет вычислительной математики и кибернетики (ВМК), Москва | Август 2022 — Август 2026

- Deep Learning School (DLS), направления Computer Vision и NLP — Школа глубокого обучения МФТИ.
- Летняя школа по A/B-тестированию (A/B testing), X5 Tech — лето 2026 (сертификат № 9074503).